

Laissez des traces de votre raisonnement pour toutes les questions !

For all questions, show your work !

1. (10 points) Réseau de Neurones, Classification

On considère l'entraînement d'un réseau de neurones type "feedforward". Pour cette question, on s'intéresse à une seule itération de l'algorithme SGD sur un seul exemple $(\mathbf{x}, y)$. On désigne par $f(\mathbf{x}, \boldsymbol{\theta})$ la sortie du réseau qui a pour paramètres $\boldsymbol{\theta}$, par g la fonction d'activation de la couche de sortie et par $a(\mathbf{x}, \boldsymbol{\theta})$ les pré-activations de la couche de sortie, i.e. $f(\mathbf{x}, \boldsymbol{\theta}) = g(a(\mathbf{x}, \boldsymbol{\theta}))$.

- En supposant que le but du réseau, décrit ci-dessus, est de faire de la classification binaire, quel serait une fonction d'activation g appropriée ?
- Que représente la sortie du réseau étant donnée cette fonction g ?
- Soit $L_{CE}(f(\mathbf{x}, \boldsymbol{\theta}), y)$ la fonction de perte "entropie croisée". Exprimer cette perte comme une fonction de $f(\mathbf{x}, \boldsymbol{\theta})$ et y .
- Calculer les dérivées partielles $\frac{\partial L_{CE}(f(\mathbf{x}, \boldsymbol{\theta}), y)}{\partial a(\mathbf{x}, \boldsymbol{\theta})}$.
- Soit $L_{MSE}(f(\mathbf{x}, \boldsymbol{\theta}), y)$ l'erreur quadratique moyenne. Exprimer cette perte comme une fonction de $f(\mathbf{x}, \boldsymbol{\theta})$ et y .
- Calculer les dérivées partielles $\frac{\partial L_{MSE}(f(\mathbf{x}, \boldsymbol{\theta}), y)}{\partial a(\mathbf{x}, \boldsymbol{\theta})}$.
- En se basant sur vos réponses précédentes, quelle serait la fonction de perte appropriée. Justifier votre choix.

2. (15 point) Réseau de Neurones à Convolution.

- Décrire trois éléments qui différencie les réseaux de neurones à convolution des réseaux "feedforward" standards. Pour chaque élément, discuter des avantages (calculatoires, statistiques, etc.) qu'il apporte lorsque le réseau est appliqué sur des images.
- La plupart des applications de CNNs impliquent une étape de standardisation des données, où les images en entrées sont redimensionnées vers une taille fixe. Décrire deux manières différentes qui permettent d'appliquer les CNNs à des images de taille variable pour une tâche de classification.
- Calculer les convolutions "full", "valid", and "same" (avec inversion du noyau i.e. "kernel flipping") pour les matrices 1D suivantes :

entre : $[1, 2, 3, 4] * \text{noyau} : [1, 0, 2]$

3. (20 point) Réseau de Neurones Récurrents.

On considère une variante de l'architecture LSTM :

$$\begin{aligned} \mathbf{f}_t &= \text{sigmoid}(W_f \mathbf{x}_t + U_f \mathbf{h}_{t-1} + \mathbf{b}_f) \\ \mathbf{o}_t &= \text{sigmoid}(W_o \mathbf{x}_t + U_o \mathbf{h}_{t-1} + \mathbf{b}_o) \\ \mathbf{c}_t &= \mathbf{f}_t \odot (1 - \mathbf{f}_t) \odot \mathbf{c}_{t-1} + \tanh(W_c \mathbf{x}_t + U_c \mathbf{h}_{t-1} + \mathbf{b}_c) \\ \mathbf{h}_t &= \mathbf{o}_t \odot \tanh(\mathbf{c}_t) \\ y_t &= W_y \mathbf{h}_t + d \end{aligned}$$

- (a) En supposant que chaque $\mathbf{x}_t, \mathbf{h}_t, \mathbf{f}_t, \mathbf{o}_t, \mathbf{c}_t$, et $y_t \in \mathbb{R}$ sont tous unidimensionnel et que les matrices de poids du modèle $W_f, U_f, W_o, U_o, W_c, U_c$ sont de taille 1×1 (i.e. des nombres scalaires) tous comme les paramètres de biais $\mathbf{b}_f, \mathbf{b}_o, \mathbf{b}_c$, et d . Calculer la dérivative $\frac{dc_1}{dx_0}$.
- (b) Comparer cette variante du LSTM avec un RNN sigmoid standard :

$$\begin{aligned}\mathbf{h}_t &= \text{sigmoid}(W\mathbf{x}_t + U\mathbf{h}_{t-1}) \\ y_t &= W_y\mathbf{h}_t + d.\end{aligned}$$

Comparer la capacité de ces modèles à apprendre des dépendences “à long-terme” entre les entrées du modèle et la sortie par retropropagation du gradient ? (Justifier votre réponse.)

4. **(10 point) Optimisation.**

Comparer brièvement et contraster les paires suivantes d’algorithmes d’optimisation : (spécifier les différences, avantages et désavantages)

- (a) Descente de Gradient Stochastique (SGD) et Adagrad,
- (b) Adagrad et RMSprop,
- (c) RMSprop et Adam,
- (d) Méthode de Newton et le Gradient Conjugué,
- (e) Gradient Conjugué et BFGS.

5. **(20 point) Régularisation.**

- (a) Pourquoi la capacité d’un modèle augmente lorsque le nombre d’itérations augmente ?
- (b) Expliquez l’intuition derrière le lien entre l’early-stopping et le L_2 weight decay pour un modèle linéaire.
- (c) Considérer l’application de “Dropout” à un réseau sans couche cachée pour une tâche de classification à k -classes. On note $\mathbf{x} \in \mathbb{R}^n$ l’entrée du réseau, $y \in \{0, 1, \dots, k-1\}$ sa sortie, W sa matrice de poids et $\mathbf{v}$ le masque de Dropout. La sortie du réseau avec Dropout donnée par (avec $\odot$ étant la multiplication “element-wise”)

$$P(y = y \mid \mathbf{x}, \mathbf{d}) = \text{softmax} \left(W^\top (\mathbf{d} \odot \mathbf{x}) + \mathbf{b} \right)_y$$

On définit l’ensemble des classificateurs “Dropout” à k -classes par

$$P_{\text{ensemble}}(y = y \mid \mathbf{x}) = \frac{\tilde{P}_{\text{ensemble}}(y = y \mid \mathbf{x})}{\sum_{y'} \tilde{P}_{\text{ensemble}}(y = y' \mid \mathbf{x})},$$

où

$$\tilde{P}_{\text{ensemble}}(y = y \mid \mathbf{x}) = \sqrt[n]{\prod_{\mathbf{d} \in \{0,1\}^n} P(y = y \mid \mathbf{x}, \mathbf{d})}$$

Prouver que le réseau sans “Dropout” avec ses poids multipliés par $1/2$:

$$P(y = y \mid \mathbf{x}) \propto \exp \left(\frac{1}{2} W_{y,:}^\top \mathbf{x} + \mathbf{b} \right)$$

est équivalent à la moyenne géométrique sur l’ensemble des modèles générés par l’ensemble “Dropout”.

6. (15 point) VAE.

Considérer un modèle génératif qui utilise la factorisation suivante $p(x, z) = p(x | z)p(z)$, où $p(x | z)$ est caractérisée par un réseau de neurones, i.e. $p(x | z) = p(x; f(z; \theta))$, où θ est l'ensemble des paramètres pour le modèle génératif (i.e. decoder).

On suppose que $z \in \mathbf{R}^K$, ce qui implique un espace latent continue, et $p(z) = \mathcal{N}(0, I_K)$. Dans le cas de l'autoencodeur variationnel, on maximise la “variational lower bound” de la log-vraisemblance $\mathcal{L}(\theta, \phi) \leq \log p(x)$, qui est exprimée comme

$$\mathcal{L}(\theta, \phi) = \mathbf{E}_{q_\phi}[\log p(x|z)] - \mathbf{KL}(q_\phi(z|x) || p_\theta(z)), \quad (1)$$

où ϕ est l'ensemble des paramètres pour le réseau d'inférence (i.e. encoder). L'astuce de reparamétrisation ré-exprime z comme étant

$$z = \mu(x) + \sigma(x) \odot \epsilon \quad (2)$$

où $\epsilon \sim \mathcal{N}(\epsilon; 0, I)$.

- (a) Quel est le but de l'astuce de reparamétrisation ?
- (b) Comme discuté en classe, la méthode champ-moyen (mean-field) traditionnel correspond à une factorisation de la distribution à posteriori comme un produit des distributions : $q^{mf}(z_i) = \prod_j \mathcal{N}(z_{i,j} | m_{i,j}, \sigma_{i,j}^2)$ et maximise la “lower bound” directement par rapport au paramètre variationnel $m_{i,j}$ et $\sigma_{i,j}^2$. Est-ce que le réseau d'inférence q_ϕ utilisé dans le VAE peut être plus performant que la méthode champ-moyen (en terme de maximisation du “upper bound” dans (e.q. 1) ? (Justifier votre réponse.)
- (c) Quel est l'avantage d'utiliser un encodeur comme dans le VAE ?
- (d) Est-ce que l'approche “Inverse Auto-regressive Flow (IAF)” pour l'inférence dans le VAE est plus performante que l'approximation champ-moyen ? (Justifier votre réponse.)

7. (10 point) Attention

En classe, on a vu deux stratégies basiques pour la traduction machine, une basée sur le modèle Seq2Seq et une basée sur l'attention “douce” (soft-attention) de Bahndau et al. (le cours présenté par Dima). Décrire les deux approches et préciser quelles sont leurs différences (inclure une description mathématique de l'attention douce). Quel avantage présente l'attention douce sur l'approche Seq2Seq ?